



Pontificia Universidad Católica del Ecuador

Ingeniería en Ciencia de Datos

Documento Integrador

Spotify Hit Predictor

Clasificación de canciones con potencial de popularidad

Integrantes

Gabriela Cárdenas

Ana Hidalgo

David Jaramillo

Sebastián Quijía

Emilio Andrade

2025

1. Resumen Ejecutivo

El proyecto **Spotify Hit Predictor** busca apoyar a equipos A&R, analistas musicales y áreas comerciales en la priorización de canciones con potencial de popularidad. El problema surge porque revisar manualmente un catálogo amplio requiere tiempo, presupuesto y criterio especializado. En este proceso, algunas canciones con potencial pueden quedar fuera de revisión, mientras que otras pueden recibir inversión sin generar resultados relevantes.

Para responder a este problema se construyó un modelo de clasificación binaria que predice si una canción alcanzará una popularidad mayor o igual a 50 en Spotify. La variable objetivo fue **popular**, donde la clase positiva representa canciones con popularidad igual o superior a dicho umbral. El modelo utiliza características de audio, duración, explicitud, géneros musicales y variables derivadas como `rhythm_missing`, `energy_tempo` e `is_long_track`.

El modelo seleccionado fue **HistGradientBoostingClassifier**, optimizado mediante *RandomizedSearchCV*. Se eligió este enfoque porque el problema presenta desbalance de clases: 74.24 % de canciones no populares y 25.76 % de canciones populares. Por esta razón, además de Accuracy, se priorizaron métricas como Recall, F1-score, ROC-AUC y PR-AUC.

En test se evaluaron dos estrategias. La estrategia equilibrada, con umbral 0.55, obtuvo Accuracy de 80.13 %, Precision de 55.95 %, Recall de 74.84 % y F1-score de 64.03 %. La estrategia de descubrimiento, con umbral 0.35, redujo la precisión pero elevó el Recall a 90.35 %, lo que permite detectar más canciones populares potenciales. En términos de negocio, la simulación estimó un impacto de \$13,652,000 para la estrategia equilibrada y \$18,890,000 para la estrategia de descubrimiento. Estos valores son académicos e ilustrativos, pero muestran que el modelo puede apoyar la priorización de revisión humana y la asignación de recursos promocionales.

2. Metodología y Ciclo de Vida

2.1. Comprensión del problema

El proyecto parte de una necesidad de negocio: priorizar canciones con mayor probabilidad de tener desempeño comercial relevante. El usuario principal es el equipo A&R, encargado de revisar canciones, detectar oportunidades y recomendar inversión promocional. También se consideran usuarios secundarios como analistas musicales, equipos comerciales y líderes de negocio.

La pregunta de modelado fue: *¿puede estimarse, a partir de características musicales y de género, si una canción alcanzará una popularidad igual o superior a 50 en Spotify?*

2.2. Datos y preparación

El dataset original contenía aproximadamente 114,000 registros a nivel canción-género. Después de la limpieza y consolidación, se obtuvo un dataset final de 89,730 canciones únicas identificadas por `track_id`. La división final fue estratificada: 62,808 canciones para entrenamiento, 13,462 para validación y 13,460 para test.

Las principales decisiones de preparación fueron:

- Eliminar columnas de índice duplicadas sin valor predictivo.
- Eliminar un registro inválido con duración igual a cero y sin información musical útil.
- Consolidar registros repetidos por `track_id` para evitar fuga de información entre train, validation y test.
- Agrupar múltiples géneros asociados a una misma canción.

- Definir la variable objetivo **popular** usando el umbral de popularidad mayor o igual a 50.
- Tratar valores **tempo** = 0 y **time_signature** = 0 como ausencia técnica de medición rítmica.
- Crear variables derivadas para capturar información adicional sobre ritmo, energía y duración.

Estas decisiones fueron registradas en el *Decision Log* para mantener trazabilidad metodológica. Una decisión importante fue no conservar canciones repetidas en diferentes particiones, ya que eso habría provocado fuga de datos y una evaluación artificialmente optimista.

2.3. Ingeniería de características

Además de las variables originales del conjunto de datos, se desarrollaron nuevas características con el propósito de capturar relaciones que no eran evidentes de forma individual. Entre ellas destacan **rhythm_missing**, que identifica la ausencia de información rítmica; **energy_tempo**, que representa la interacción entre el nivel de energía y el tempo de una canción; e **is_long_track**, utilizada para identificar canciones con una duración superior a diez minutos.

Estas variables fueron incorporadas después del análisis exploratorio y de las decisiones documentadas durante el desarrollo del proyecto. El objetivo fue enriquecer la representación de las canciones sin introducir información que pudiera generar fuga de datos o afectar la validez del proceso de entrenamiento.

2.4. Selección del modelo

Como parte de la fase de modelado se evaluaron distintas alternativas para resolver el problema de clasificación. El modelo finalmente seleccionado fue **HistGradientBoostingClassifier**, debido a que presentó el mejor equilibrio entre capacidad predictiva, estabilidad y comportamiento frente al desbalance de clases.

La optimización de hiperparámetros se realizó mediante *RandomizedSearchCV*, evaluando doce configuraciones diferentes utilizando validación cruzada de tres particiones. Como criterio principal de selección se empleó la métrica **PR-AUC**, ya que resulta más adecuada cuando la clase positiva representa únicamente una fracción del conjunto de datos.

El modelo final utilizó un total de 131 variables después del proceso de transformación y codificación de los datos.

2.5. Estrategias de decisión

Una característica importante del proyecto fue la definición de dos estrategias de decisión a partir de distintos umbrales de probabilidad.

Estrategia	Umbral	Objetivo
Equilibrada	0.55	Balance entre precisión y cobertura.
Descubrimiento	0.35	Detectar la mayor cantidad posible de canciones populares.

Cuadro 1: Estrategias de decisión utilizadas por el modelo.

La estrategia equilibrada busca reducir la cantidad de falsos positivos y mantener un volumen razonable de canciones para revisión manual. Por otro lado, la estrategia de descubrimiento prioriza maximizar el Recall, permitiendo identificar un mayor número de canciones potencialmente

exitosas, aunque incrementando la cantidad de falsos positivos que deberán ser evaluados por el equipo A&R.

Esta separación permite adaptar el comportamiento del modelo según el contexto operativo y la disponibilidad de recursos para la revisión humana.

3. Resultados y Evaluación

3.1. Distribución de la variable objetivo

Antes del entrenamiento se analizó la distribución de la variable objetivo para identificar posibles problemas de desbalance.




Figura 1: Distribución de canciones populares y no populares.

Como puede observarse, aproximadamente el 74.24 % de las canciones corresponden a la clase *No popular*, mientras que únicamente el 25.76 % pertenece a la clase *Popular*. Este comportamiento justificó el uso de métricas adicionales al Accuracy, especialmente Precision, Recall, F1-score y PR-AUC, ya que una alta exactitud por sí sola podría ocultar un bajo desempeño sobre la clase minoritaria.

3.2. Análisis exploratorio

Durante el análisis exploratorio también se evaluó la relación lineal entre las variables musicales y la popularidad.




Figura 2: Correlación entre las principales variables de audio y la popularidad.

Las correlaciones obtenidas fueron relativamente bajas. Variables como *loudness* y *danceability* mostraron relaciones positivas moderadas, mientras que *instrumentalness* presentó la correlación negativa más alta. Estos resultados indican que ninguna variable explica por sí sola la popularidad de una canción, lo que justifica el uso de un modelo no lineal capaz de capturar relaciones complejas entre múltiples características.

3.3. Resultados cuantitativos

Los resultados obtenidos sobre el conjunto de prueba se resumen en la Tabla 2.

Cuadro 2: Resultados finales del modelo sobre el conjunto de prueba.

Métrica	Equilibrada	Descubrimiento
Accuracy	80.13 %	70.29 %
Precision	55.95 %	43.76 %
Recall	74.84 %	90.35 %
F1-score	64.03 %	58.96 %
ROC-AUC	0.870	0.870
PR-AUC	0.686	0.686

La estrategia equilibrada obtuvo mejores resultados en términos de precisión y F1-score, siendo adecuada cuando la capacidad de revisión humana es limitada. En cambio, la estrategia de descubrimiento incrementó significativamente el Recall, permitiendo identificar una mayor cantidad de canciones potencialmente populares a costa de un aumento en falsos positivos.

Desde una perspectiva de negocio, la elección entre ambas estrategias dependerá de los recursos disponibles y del objetivo específico de la campaña de scouting musical.

3.4. Matrices de confusión

Además de las métricas globales, se analizaron las matrices de confusión para comprender con mayor detalle el comportamiento del modelo bajo ambas estrategias de decisión.




Figura 3: Matrices de confusión para las estrategias equilibrada y de descubrimiento.

En la estrategia equilibrada el modelo clasificó correctamente 8 406 canciones no populares y 2 380 canciones populares. Los principales errores corresponden a 1 874 falsos positivos y 800 falsos negativos. Esto representa un equilibrio entre precisión y capacidad de detección, manteniendo un número razonable de canciones para revisión humana.

En contraste, la estrategia de descubrimiento redujo los falsos negativos de 800 a únicamente 307 casos, incrementando el número de canciones populares detectadas hasta 2 873. Sin embargo, esta mejora estuvo acompañada por un incremento considerable de falsos positivos, que pasaron de 1 874 a 3 692. En términos prácticos, el modelo recomienda revisar un mayor número de canciones para disminuir el riesgo de dejar fuera posibles éxitos comerciales.

Estos resultados muestran el compromiso natural entre precisión y cobertura. Cuando el costo de perder una canción potencialmente exitosa es alto, la estrategia de descubrimiento resulta más conveniente. Si la capacidad de revisión humana es limitada, la estrategia equilibrada representa una mejor alternativa.

3.5. Impacto de negocio

Con el propósito de traducir las métricas técnicas a un contexto de negocio, se desarrolló una simulación utilizando valores económicos ilustrativos para cada tipo de predicción.

Cuadro 3: Supuestos utilizados para la simulación del impacto de negocio.

Resultado	Valor ilustrativo
Verdadero positivo	+\$10 000
Falso positivo	-\$2 000
Falso negativo	-\$8 000
Verdadero negativo	\$0

Bajo estos supuestos se obtuvo el siguiente impacto estimado.

Cuadro 4: Comparación del impacto de negocio por estrategia.

Estrategia	Impacto estimado	Canciones para revisión
Equilibrada (0.55)	\$13 652 000	4 254
Descubrimiento (0.35)	\$18 890 000	6 565

Aunque los valores económicos utilizados son únicamente ilustrativos, la simulación permite observar que ambas estrategias generan beneficios distintos según el objetivo del negocio. La estrategia equilibrada reduce la carga operativa al requerir revisar menos canciones, mientras que la estrategia de descubrimiento incrementa el impacto esperado debido a que identifica una mayor cantidad de canciones potencialmente populares.

La decisión final dependerá de la capacidad del equipo A&R para revisar nuevas canciones y del presupuesto disponible para campañas promocionales.

3.6. Análisis de Fairness

El proyecto incorporó una evaluación de fairness con el objetivo de verificar si el desempeño del modelo variaba entre distintos segmentos musicales.

El análisis se realizó desde dos perspectivas. En primer lugar, se evaluó el desempeño por género individual considerando únicamente aquellos con suficiente representación dentro del conjunto de datos. Posteriormente, se construyeron dos grupos agregados:

- Mainstream: Pop, EDM, Hip-Hop y Rock.
- Latino / Emergente: Afrobeat, Indie, Latino, Reggaetón y Salsa.

Los resultados muestran que el modelo obtiene un mejor desempeño para el grupo Mainstream.

Cuadro 5: Brechas de fairness entre grupos musicales.

Estrategia	Brecha Precision	Brecha Recall	Brecha F1
Equilibrada	18.49 pp	24.96 pp	21.26 pp
Descubrimiento	19.40 pp	18.56 pp	21.13 pp

Aunque la estrategia de descubrimiento reduce la diferencia de Recall entre grupos, ambas configuraciones mantienen brechas superiores a diez puntos porcentuales. Esto sugiere que el modelo identifica con mayor facilidad canciones pertenecientes al segmento Mainstream.

Es importante aclarar que estas diferencias no constituyen evidencia de discriminación automática. Los segmentos musicales presentan distribuciones distintas y diferentes tasas base de popularidad. Sin embargo, sí representan un riesgo potencial que debe monitorearse antes de utilizar el modelo como apoyo para decisiones comerciales.

Como medida de mitigación se recomienda mantener revisión humana obligatoria, monitorear periódicamente las métricas por grupo musical y reevaluar el modelo conforme se incorporen nuevos datos.

4. Lecciones Aprendidas y Próximos Pasos

Durante el desarrollo del proyecto se identificaron diversos aprendizajes relacionados tanto con la preparación de datos como con la construcción y evaluación del modelo.

La primera lección fue que la calidad de los datos tiene un impacto directo sobre el desempeño del modelo. La consolidación de registros mediante `track_id` permitió evitar fuga de información y producir una evaluación mucho más representativa del comportamiento esperado en producción.

La segunda lección fue que la selección del umbral de decisión puede modificar significativamente el comportamiento del modelo sin necesidad de entrenar un algoritmo diferente. Dependiendo del contexto de negocio, puede resultar más conveniente maximizar la precisión o priorizar la detección de canciones potencialmente exitosas.

Finalmente, el análisis de fairness evidenció que un modelo con buenas métricas globales todavía puede presentar diferencias importantes entre grupos específicos. Esto resalta la importancia de complementar la evaluación tradicional con métricas de equidad y análisis éticos.

4.1. Limitaciones

Entre las principales limitaciones identificadas durante el proyecto destacan las siguientes:

- La popularidad de una canción depende de numerosos factores externos que no están representados en el conjunto de datos, como campañas de marketing, redes sociales o reconocimiento previo del artista.
- El conjunto de datos utilizado corresponde a un escenario académico y no representa necesariamente el comportamiento completo del mercado musical.
- El modelo presenta diferencias de desempeño entre algunos segmentos musicales, por lo que requiere monitoreo continuo.
- La simulación económica utiliza valores ilustrativos y no representa ingresos reales.
- El comportamiento de los gustos musicales cambia constantemente, por lo que el modelo debe actualizarse periódicamente para evitar degradación del desempeño.

4.2. Próximos pasos

Como trabajo futuro se propone:

- Incorporar información relacionada con artistas, historial de reproducciones y presencia en playlists.
- Validar el modelo utilizando datos recientes del mercado musical.
- Monitorear continuamente las métricas de desempeño y fairness.
- Evaluar técnicas adicionales de explicabilidad para facilitar la interpretación de las predicciones.
- Integrar el modelo dentro de un flujo de trabajo que apoye al equipo A&R sin reemplazar el criterio humano.

5. Conclusiones

El desarrollo del proyecto permitió construir un sistema predictivo capaz de estimar el potencial de popularidad de una canción utilizando información de audio y características derivadas. El modelo HistGradientBoosting presentó un desempeño sólido y demostró ser una alternativa adecuada para apoyar procesos de priorización musical.

Los resultados evidencian que la estrategia equilibrada constituye una opción apropiada cuando la capacidad de revisión es limitada, mientras que la estrategia de descubrimiento resulta más conveniente cuando el objetivo consiste en maximizar la detección de canciones potencialmente exitosas.

Desde la perspectiva de negocio, la simulación de impacto mostró que ambas estrategias generan beneficios distintos dependiendo del contexto operativo. Asimismo, la evaluación de fairness permitió identificar diferencias entre segmentos musicales, lo que resalta la necesidad de mantener supervisión humana y monitoreo continuo antes de utilizar el modelo en escenarios reales.

En conjunto, el proyecto demuestra cómo la Ciencia de Datos puede apoyar la toma de decisiones dentro de la industria musical mediante modelos predictivos interpretables, evaluados desde una perspectiva técnica, de negocio y ética.